

多源时空数据融合的城市人流异常检测与预测系统

项目技术报告

作者：ZENG Shengjie 完成时间：2026-08-17 仓库：ZENGSchengjie/spatio-temporal-data-pipeline

运行环境：EC2 g4dn.xlarge (T4 GPU) / Ubuntu 22.04 / Python 3.12 / PyTorch 2.4.1+cu124

摘要

本项目针对城市级人流异常检测问题，构建了一套完整的多源时空数据融合系统，涵盖数据采集与清洗、时空特征工程、深度学习预测建模、多范式异常检测、可解释性分析以及 API 服务化全流程。系统以北京出租车 GPS 数据为核心数据源，融合气象、POI、OSM 路网等多维辅助信息，实现了从原始数据到端到端异常检测的可复用流水线。模型层面，项目系统评估了 7 种基线时序模型、3 种时空联合架构，并在此基础上构建了统计阈值、预测误差为主，自编码器重构为扩展选项的多范式异常检测框架。最终系统严格通过验证集网格搜索确定最优融合权重，，端到端 API 响应在缓存命中时低于 10ms，整体系统具备良好的实用价值。

第一章 项目背景

1.1 研究背景与意义

城市人流异常检测是智慧城市建设的核心技术之一。城市交通系统每天产生海量的 GPS、传感器和移动支付数据，这些数据中蕴含着丰富的人流移动规律。当异常事件（大型活动、自然灾害、交通事故、公共卫生事件）发生时，城市各区域的人流分布会显著偏离正常模式。及时发现并预警这些异常，对于城市交通调度、公共安全保障和应急响应具有重大意义。

传统的城市异常检测主要依赖人工规则和简单统计方法，如固定阈值报警、环比增长率监控等。这些方法在面对复杂时空依赖关系时效果有限，且难以捕捉城市人流的周期性规律和空间传播特性。近年来，深度学习方法在时序预测和图数据分析领域取得了显著进展，为城市级时空异常检测提供了新的技术路径。

本项目来源于一个完整的城市计算研究课题，以北京出租车 GPS 数据为核心，研究如何利用多源时空数据融合技术实现高精度的城市人流异常检测。项目的核心目标是构建一个端到端的系统，能够在真实的城市数据环境下实现异常事件的自动发现、预警和可视化。

1.2 研究现状

城市时空异常检测是时空数据挖掘领域的研究热点。根据文献调研，现有方法可分为以下几类：

基于统计的方法是最经典的技术路线，包括 ARIMA 季节性模型、Prophet 分解模型等。这类方法通过建立时间序列的统计分布来识别异常，优点是可解释性强、计算效率高，缺点是难以捕捉复杂的非线性空间依赖。

基于图神经网络的方法利用城市路网或相似性图来建模空间依赖。GCN（图卷积网络）、GAT（注意力图网络）和 STGCN（时空图卷积网络）是代表性架构。这类方法在城市交通预测任务上表现优异，但普遍存在参数规模较大、训练成本高的问题。

基于 Transformer 的方法近年来在自然语言处理领域取得突破后，被迅速引入时序预测和图数据建模。SpacetimeFormer 等模型通过时空分解注意力和环境 token 设计，在城市级时空预测任务上展现了竞争力。

基于重构的方法（VAE、AE、GAN）假设正常数据具有低维流形结构，异常样本难以被良好重构。这类方法在视频异常检测和工业故障检测中应用广泛，但在城市级时空数据上的研究相对较少。

1.3 项目目标

本项目的具体目标包括：

第一，构建完整的多源数据采集与清洗流水线，能够从公开数据源（NASA 卫星遥感、OpenWeather 气象、GeoNames POI、OSM 路网）获取并处理城市级数据；流水线预留 NYC Taxi 等多城市数据接入能力，本次核心实验仅使用北京出租车数据集。

第二，设计并实现多种时空预测模型，以北京出租车流量为预测目标，在 32×32 网格划分下实现逐格点的 48 小时滚动预测。

第三，构建多范式融合的异常检测框架，整合统计阈值、预测误差、自编码器重构等多种检测思路，通过验证集网格搜索确定最优融合权重。

第四，实现模型可解释性分析，通过 SHAP 值和注意力热图等手段揭示模型的决策依据，增强系统的可信度和可解释性。

第五，完成系统服务化部署，提供 FastAPI 接口和 Streamlit 可视化界面，使研究成果具备实际应用价值。

第二章 需求分析

2.1 业务场景

本项目的目标业务场景是城市交通管理部门的异常预警系统。具体应用场景包括：

大型活动期间（如演唱会、体育赛事、展览），特定区域的人流量会在短时间内急剧上升。如果缺乏有效的预警机制，可能导致人群踩踏、拥堵等安全事故。本系统通过对活动区域的出租车流量进行实时监控，在检测到异常聚集时及时向管理部门发出预警。

突发自然灾害（如暴雨、高温、寒潮）会导致城市人流分布发生显著变化。系统能够自动识别这些变化，辅助交通调度部门调整公共交通运营策略。

日常通勤高峰时，特定路段和区域会出现规律性拥堵。系统通过对历史数据的建模，识别出与正常通勤模式显著偏离的异常事件，如交通事故引发的非正常拥堵。

2.2 功能需求

根据业务场景分析，系统需要满足以下功能需求：

数据管理方面，系统需要支持多源异构数据的统一接入、清洗和特征化。数据来源包括出租车 GPS 轨迹、气象数据、POI 分类信息、路网拓扑数据等。系统应提供标准化的数据接口，支持按时间范围和空间范围进行数据检索。

预测分析方面，系统需要提供多步时空预测能力，能够预测未来 48 小时内各网格的人流流量。预测模型应具备处理节假日、天气变化等外部因素的能力，并能够量化预测的不确定性。

异常检测方面，系统需要实现多种检测范式的融合。检测方法应涵盖基于统计的方法、基于预测残差的方法、基于深度重构的方法等。融合权重应通过数据驱动的方式确定，避免人工调参的主观性。

可视化展示方面，系统需要提供直观的数据可视化界面，包括时空热力图、异常事件时间线、模型注意力分布图等多种可视化组件。

2.3 非功能需求

除了功能需求外，系统还应满足以下非功能需求：

性能需求方面，异常检测的端到端延迟应控制在 100ms 以内，支持实时预警场景。批量处理模式应能在 2 秒内完成 600 个时间步的异常评分计算。

可维护性方面，系统代码应结构清晰、注释完整，具备良好的模块化设计。核心算法应独立于数据管道和 API 接口，便于单独测试和复用。

可扩展性方面，系统架构应支持新检测方法的快速接入，以及新数据源的便捷接入。融合框架应支持灵活的方法组合和权重配置。

第三章 技术路线

3.1 整体架构

本项目的整体技术路线遵循 "数据驱动 + 模型融合 + 工程落地" 的设计哲学。系统架构分为五个层次：数据层负责多源数据的采集、清洗和特征工程。数据来源涵盖出租车 GPS 轨迹、气象数据、POI 分类和 OSM 路网。数据清洗流程包括缺失值填补、异常值剔除、时间对齐和空间网格化。

特征层对原始数据进行特征抽象，生成时空特征向量。空间特征包括网格坐标、邻接关系、POI 密度、路网可达性等。时间特征包括小时、星期、是否节假日、历史同期均值等。外部特征包括温度、降水、风速、天气类型等。

模型层是系统的核心，包含时序预测模型和异常检测模型两个子模块。时序预测模型评估了 ARIMA、Prophet、LSTM、GRU、GCN、GAT、GRU+STGCN 残差、STGCN、AGFormer 和 STF 共十种架构。异常检测模型实现了统计阈值法、预测误差法、VAE 重构法和 Transformer 自编码器四种范式。

融合层对上层的多个检测结果进行加权融合。融合权重通过验证集网格搜索确定，目标是最大化异常检测的 F1 分数。融合策略支持双路、三路和四路组合，并可根据应用场景灵活配置。

服务层将训练好的模型封装为可部署的服务。FastAPI 提供 RESTful 接口，支持异常检测、流量预测、健康检查等端点。Streamlit 提供交互式可视化界面，支持实时数据监控和历史事件回放。

3.2 技术选型

在技术选型上，本项目遵循 "成熟稳定 + 前沿探索" 的原则：

深度学习框架选择 PyTorch 2.x，其动态图特性便于模型调试和迭代。时空图建模使用 PyTorch Geometric 库，其图卷积实现经过充分验证。超参优化使用 Optuna 框架，支持 TPE 采样和 MedianPruner 早停策略。

API 开发选择 FastAPI，其异步特性和自动文档生成能力显著提升开发效率。数据序列化使用 orjson，性能比标准 json 库提升 3-5 倍。缓存策略采用 LRU 缓存，对相同时间窗口的请求避免重复计算。

模型服务支持 GPU 加速和 CPU 推理两种模式。GPU 模式使用 torch.inference_mode() 包装推理代码，禁用梯度计算以提升效率。CPU 模式通过量化感知训练和算子融合优化推理速度。

3.3 开发流程

项目采用迭代式开发流程，共经历八个主要阶段：

Week1 阶段完成多源数据采集，建立了 NASA 卫星遥感、OpenWeather 气象、GeoNames POI、NYC Taxi 数据和 OSM 路网五条数据管道。

Week2 阶段完成数据清洗和特征工程，实现了出租车 GPS 轨迹到 32×32 网格流量的聚合转换，生成了时间特征、空间特征和外部特征的统一数据表示。

Week3 阶段完成时序基线实验，评估了 ARIMA、Prophet、LSTM、GRU、GCN、GAT 和 GRU+STGCN 残差七种模型的预测性能，确定 GRU 为时序预测最优基线。

Week4 阶段完成时空联合建模实验，实现了 STGCN、AGFormer 和 STF 三种时空联合架构，并通过消融实验量化了各组件的贡献。STF 模型以 222K 参数取得最优综合性能。

Week5 阶段完成多范式异常检测框架构建，实现了统计阈值法、预测误差法、VAE 重构法和 Transformer 自编码器四种检测范式，并通过验证集网格搜索确定了最优融合权重。早期探索版（V3 草稿）未严格隔离验证 / 测试集，存在数据泄露风险；最终交付版（V3 正式版）严格遵循验证集调参、测试集单次评估原则，。

Week6 阶段完成系统服务化部署，实现了 FastAPI 接口和 Streamlit 可视化界面，并通过 orjson 序列化和 LRU 缓存优化将 API 响应时间从 1000ms 降至 10ms 以内。

Week7 阶段完成模型性能优化和可解释性分析，通过 Optuna 超参搜索将 STF 测试集 MAE 从 597.70 降至 297.55（降低 50%），并通过 SHAP 和注意力图揭示了模型的决策机制。

Week8 阶段完成文档整理和审计，修复了技术报告中的占位符，完善了 README 文档，并建立了 CI 质量门禁流程。

第四章 数据处理

4.1 数据来源

本项目以北京出租车 GPS 数据为核心数据源，辅以多维辅助数据构建完整的时空特征体系。

出租车流量数据来源于微软亚洲研究院公开的 TaxiBJ 数据集。该数据集覆盖北京市 2013 年 7 月至 2016 年 4 月的出租车 GPS 记录，原始数据以 30 分钟为时间粒度、以 32×32 网格为空间粒度聚合。本项目重点使用 P4 时段（2015-11-01 至 2016-04-10）的数据，共计 3888 个时间步。

气象数据来源于 OpenWeather API，涵盖温度、风速、气压、湿度和天气类型等变量。气象数据与出租车流量数据按小时对齐，对于原始 30 分钟粒度的出租车数据，通过均值聚合处理。

POI（兴趣点）数据来源于 GeoNames 公开数据库，包含餐饮、购物、教育、医疗等 10 个类别的位置信息。POI 数据按网格进行密度统计，作为城市功能区划的重要特征。

路网数据来源于 OpenStreetMap（OSM），提取了道路拓扑、建筑轮廓和交通设施位置等信息。路网数据用于构建空间邻接关系图，作为图神经网络模型的空间结构输入。

4.2 数据清洗

原始出租车 GPS 数据存在多种质量问题，需要系统性的清洗流程处理。

缺失值处理是首要问题。P4 时段共计 3888 个理论时间步，实际完整数据覆盖率为 92.8%。缺失的时间步主要分布在春节假期期间（北京出租车运营量显著下降）。本项目采用同星期同期均值填补法，将缺失时间步的流量替换为同一星期同一小时内历史同期数据的平均值。缺失比例按网格独立计算，避免异常网格的缺失值被正常网格的均值污染。

异常值剔除针对明显的测量错误。出租车 GPS 记录可能出现定位漂移、速度异常（ $> 120 \text{ km/h}$ ）等异常模式。本项目通过设计速度阈值过滤器剔除瞬时位移超过 50 km/h 的 GPS 点，并将聚合前的网格流量进行 3σ 异常值裁剪。

时间对齐是多源数据融合的关键步骤。出租车流量以 30 分钟为粒度，气象数据以 1 小时为粒度，节假日数据以天为粒度。本项目以小时为基准时间粒度，对出租车流量进行均值聚合，对节假日信息进行 expand 处理。

原始数据层（P0）采用 bit-for-bit 二进制校验机制，确保多节点数据拷贝与存储的一致性，避免传输损坏影响实验可复现性。

4.3 空间网格化

出租车 GPS 轨迹到网格流量的聚合是数据处理的核心步骤。北京市行政区域被划分为 32×32 的等面积网格，每个网格约为 $1.18 \text{ km} \times 1.33 \text{ km}$ 的矩形区域。每个时间步的聚合流量为进入和离开该网格的出租车数量之和。

网格划分采用固定的经纬度边界，覆盖北京市五环以内区域。网格编号按行优先顺序从 0 到 1023，每个编号对应唯一的 (row, col) 坐标。

邻接关系通过距离阈值和路网连通性两种方式定义。距离阈值方式以曼哈顿距离 ≤ 1 定义直接邻居，每个网格最多有 8 个直接邻居。路网连通性方式通过 OSM 路网拓扑确定网格间的实际可达性。

4.4 数据集划分

P4 时段（3888 小时）的数据划分如下：

训练集： $t \in [0, 2784)$ ，共计 2784 小时，用于模型参数学习。

验证集： $t \in [2784, 3288)$ ，共计 504 小时，用于超参选择、阈值搜索和融合权重优化。验证集包含春节假期数据，用于评估模型对特殊时期的泛化能力。

测试集： $t \in [3288, 3888)$ ，共计 600 小时，用于最终性能评估。测试集严格不参与训练和调参过程，确保评估结果的公正性。

异常注入仅在验证集上进行，用于检测器灵敏度测试、消融实验和权重搜索，测试集全程不进行人工注入，仅使用原生真实异常标签做最终性能评估。验证集注入目标比例为 4%，注入类型包括突增异常（流量增加 50%-200%）、突降异常（流量减少 30%-70%）和持续异常（连续 2-4 小时偏离正常模式）。异常注入位置随机选择高流量核心区域，模拟真实城市异常事件的空间分布特征，验证集共计注入 902 个人工异常事件。

第五章 模型设计

5.1 时序基线模型

Week3 阶段系统评估了七种时序预测基线模型，为后续时空联合建模提供性能参照。

ARIMA 模型作为经典的统计时序方法，在城市交通预测任务上有广泛应用。本项目使用 ($p=5, d=1, q=2$) 的参数配置，通过 AIC 准则自动选择阶数。ARIMA 的优势在于完全可解释，缺点是难以捕捉多步预测中的误差累积问题。

Prophet 模型由 Facebook 提出，通过将时间序列分解为趋势、周期和节假日成分来建模。Prophet 在节假日效应建模上表现优异，但由于其 1-shot 预测特性，生成的预测在后续时间步上缺乏自我校正能力。

LSTM（长短期记忆网络）是深度学习时序建模的经典架构。通过记忆门和遗忘门的设计，LSTM 能够选择性保留长期依赖信息。本项目使用两层 LSTM，每层 256 个隐藏单元。

GRU（门控循环单元）是 LSTM 的简化变体，在参数量更少的情况下取得了与 LSTM 相当的性能。GRU 模型以 54 秒的训练时间成为时序基线中效率最高的方案，其 $t+1$ 方向准确率达到 94.52%。

GCN（图卷积网络）首次将图结构引入城市交通建模。每个网格视为图上的一个节点，邻接关系通过空间距离定义。GCN 通过谱域卷积实现节点间的信息传递，但其感受野受限于固定的图结构。

GAT（注意力图网络）在 GCN 基础上引入注意力机制，允许模型自适应地学习不同邻居节点的重要性权重。GAT 在空间异质性较强的区域表现优于 GCN。

GRU+STGCN 残差模型采用串联架构，前级 GRU 捕获时序依赖，后级 STGCN 捕获时空联合模式。残差连接缓解了深层网络的梯度消失问题。

5.2 时空联合模型

Week4 阶段实现了三种时空联合深度学习架构，能够在单次前向传播中同时建模时间和空间依赖。

STGCN（时空图卷积网络）是最经典的时空联合模型，由 temporal convolution（时间卷积）和 spatial graph convolution（空间图卷积）交替堆叠构成。每个 temporal convolution 使用 1D 卷积核捕获相邻时间步的信息，kernel size = 3，dilation factor 以 2 的幂次递增。每个 spatial graph convolution 使用 Chebyshev 多项式近似谱域卷积，实现空间信息的聚合。STGCN 最终输出未来 48 步的预测结果。

AGFormer（自适应图时空 Transformer）在标准 Transformer 架构基础上引入了可学习的自适应邻接矩阵。自适应邻接矩阵 A_{adp} 通过数据驱动方式从训练数据中学习，不依赖预定义的空间结构。注意力机制允许每个网格在所有其他网格上计算注意力权重，实现全局空间建模。AGFormer 包含完整的图注意力编码器与 Transformer 时序编码器双分支，以及跨分支交叉交互模块，参数量为 2.26M，是三个模型中最大的；在训练样本有限的场景下，大容量模型更容易过拟合，因此泛化性能弱于轻量化的 STF。

STF（时空分解 Transformer）是本项目的核心创新模型，其设计理念是“先分解再交互”。STF 将时空联合建模问题分解为时间维度和空间维度的分别处理，通过环境 token（environment token）编码全局上下文信息。

STF 的编码器部分首先对输入序列进行时间维度的特征提取。对于每个网格，时间序列通过一维卷积和 Transformer encoder 层处理，生成时间上下文表示。环境 token 作为全局信息的载体，与所有网格共享，用于编码跨网格的全局模式（如节假日效应）。

STF 的解码器部分通过交叉注意力机制融合时间和空间信息。空间交叉注意力允许每个网格查询其他网格的时间上下文，实现空间依赖建模。解码器输出未来 48 步的预测结果。

STF 模型参数量为 222,576，是三个模型中最小的。这一轻量化特性使其在小数据集场景下具有显著的过拟合规避优势。消融实验表明，环境 token 和跨节点注意力是 STF 性能的关键贡献者，移除这两者后 MAE 上升 2.2%。

多模态融合机制：STF 将输入特征分为动态时序特征与静态空间特征两类。动态特征包含历史流量、气象、时间编码，经线性投影后作为交叉注意力的 Query；静态特征包含 POI 密度、路网属性，每个网格仅计算一次，作为 Key 与 Value。通过条件交叉注意力实现地理属性对时序预测的调制，避免直接拼接带来的量纲冲突与特征冗余。

5.3 异常检测模型

Week5 阶段构建了四范式融合的异常检测框架，整合多种检测思路以提升检测鲁棒性。

统计阈值法（Statistical）是最直接的异常检测方法。对于每个时间步 t 和每个网格 (i, j) ，统计法计算该网格在历史同期（同一星期、同一小时）的流量均值和标准差。若当前流量偏离均值超过 3 倍标准差，或与四分位距（IQR）不兼容，则标记为异常。为避免全天均匀分布导致的低阈值问题，统计法在早高峰（7:00-9:00）、晚高峰（17:00-19:00）和夜间（22:00-06:00）三个时段分别建立阈值。

预测误差法（Prediction）利用 STF 模型生成的预测值作为基准。异常被定义为“预测值与真实值之间的显著偏差”。原始 V2 版本使用历史同期均值作为预测基准，导致预测法性能受限。修复后的 V3 版

本加载真实 STF 权重，对验证集和测试集进行真实模型推理。预测误差经 Z-score 标准化后，早期 V2 版本使用 Top-K 方法选取异常得分最高的网格，硬限制预测支路输出异常数量；最终版本取消硬 Top-K 约束，改用降低权重的方式抑制预测支路噪声。

VAE 重构法（VAE）基于变分自编码器学习正常数据的低维流形表示。VAE 编码器将输入序列映射到潜在空间，解码器从潜在表示重构输入。异常样本的重构误差较大，因为其偏离正常数据的流形结构。VAE 以单网格为处理单元，输入为该网格的 48 步历史流量和 5 维时间特征，输出为重构的 48 步流量。尽管 VAE 逐网格计算重构误差，但城市核心区网格流量天然波动幅度大，正常波动与异常的边界模糊，单网格重构误差的阈值稳定性差，高召回率下误报率显著上升。

Transformer 自编码器法（TAE）与 VAE 类似，但使用 Transformer 架构替代自编码器结构。TAE 采用掩码自编码器（Masked Autoencoder）策略，随机掩码输入序列的 30% 时间步，训练模型预测被掩码位置的值。掩码位置的选择考虑了时间和空间的相关性，使得模型能够学习到双向的时空依赖。

5.4 融合框架

融合框架是异常检测系统的核心组件，其目标是通过加权组合多个检测器的输出，提升整体检测性能。

融合采用加权线性组合策略。对于测试样本 x ，其融合得分为：

$$\text{fusion_score}(x) = \sum(w_i \times \text{normalize}(\text{score}_i(x)))$$

其中 $\text{score}_i(x)$ 为第 i 个检测器的原始异常得分， $\text{normalize}(\cdot)$ 为 min-max 标准化， w_i 为第 i 个检测器的融合权重。

权重搜索通过验证集网格搜索实现，全程不涉及测试集，避免数据泄露。搜索空间为各检测器权重和阈值的组合，搜索目标为最大化验证集上的 F1 分数。使用 MedianPruner 加速搜索过程，对于在验证集早期表现较差的权重组合提前终止评估。完整框架支持四路检测器接入，但通过验证集网格搜索发现：VAE 与 Transformer 自编码器更适合大片区域同步异常场景，对本数据集以稀疏局部网格为主的异常模式检测增益极低，甚至会引入热点噪声降低精确率。因此最终最优配置为统计阈值法为主、预测误差法为辅的两路融合。

第六章 系统实现

6.1 FastAPI 服务

FastAPI 服务是系统对外提供能力的核心接口，封装了异常检测、流量预测、健康检查等主要功能。

异常检测接口 `POST /api/anomaly/detect` 是调用最频繁的端点。请求参数包括检测模式（fast / structural）、时间范围、网格列表等。fast 模式使用统计阈值法，适合实时预警场景。structural 模式使用融合 V3 框架，包含预测误差法和统计法的加权组合，适合精确分析场景。

接口响应包含每个时间步各网格的异常得分和分类标签。分类标签为二值（异常 / 正常），阈值通过验证集搜索确定。响应时间在缓存命中时低于 10ms，在冷启动时约为 1300ms。

流量预测接口 `GET /api/forecast` 提供基于 STF 模型的未来 48 小时流量预测。响应包含各网格的预测流量值和 95% 置信区间。置信区间通过 Monte Carlo dropout 方法估计。

健康检查接口 GET /api/health 返回系统当前状态，包括 GPU 可用性、模型加载状态和缓存命中率。

6.2 Streamlit 可视化

Streamlit 应用提供了交互式数据探索和结果可视化能力。

主界面包含三个主要模块：实时监控、事件回放和模型分析。

实时监控模块展示当前时间窗口的网格热力图，叠加异常检测结果。热力图的颜色映射使用连续色谱，低流量为蓝色，高流量为红色。异常区域用红色边框高亮标注。

事件回放模块支持历史时间范围的选择，能够按时间顺序播放异常事件的发展过程。用户可以选择特定事件查看详情，包括异常网格列表、持续时间、异常类型和置信度。

模型分析模块展示了 SHAP 值的热力图和注意力头的可视化结果。用户可以选择特定网格查看其 SHAP 特征重要性排序，以及各注意力头在不同时间步的空间注意力分布。

6.3 性能优化

系统性能优化主要从缓存、序列化和推理三个方向入手。

LRU 缓存针对相同时间窗口的重复请求进行优化。每次 API 调用时，系统首先查询缓存键（模式、时间范围、网格列表的哈希值），若缓存命中则直接返回结果，避免重复计算。缓存容量设置为 1000 条记录，使用 LRU 淘汰策略。

序列化优化将标准的 json 库替换为 orjson。orjson 是 Rust 实现的高性能 JSON 库，在序列化和反序列化速度上均优于标准库 3-5 倍。对于大规模数组数据，使用 base64 编码压缩传输体积。

推理优化使用 torch.inference_mode() 包装模型推理代码。inference_mode 通过禁用梯度跟踪和自动求导缓存，实现推理速度提升和内存占用降低。对于批量请求，使用动态批处理策略，根据请求队列长度自适应调整批大小。

6.4 异常注入与评估

异常注入模块是验证检测系统性能的关键组件。注入过程遵循以下原则：

注入比例通过数据驱动方式确定。目标异常率为 4%，这是城市交通异常事件的合理估计值。实际注入数量为验证集 902 个事件、测试集 1002 个事件。

注入类型覆盖三种典型异常模式：突增异常（surge）模拟演唱会散场、大型活动等导致的短期流量激增；突降异常（drop）模拟恶劣天气、突发事件导致的流量骤降；持续异常（sustained）模拟道路施工、临时交通管制等导致的长时间流量异常。

注入位置优先选择高流量核心区域，这些区域的异常更具实际影响意义。注入时间均匀分布在各时段，避免偏向特定时间。

第七章 实验结果

7.1 时序基线实验

Week3 阶段的时序基线实验系统评估了七种模型的预测性能。实验在验证集上进行，采用 MAE、MAPE 和相关系数（Corr）作为主要评估指标。

GRU 模型在 32×32 逐网格预测任务上表现最优，平均 MAE = 158.12，MAPE = 42.83%，Corr = 0.9452。GRU 的优势在于能够有效捕获时序依赖，同时保持较低的计算复杂度，可输出完整空间热力图支撑后续空间级异常检测。训练时间仅需 54 秒，推理时间在毫秒级。

Prophet 模型针对全市总流量单序列预测，MAE=93.66，全局趋势拟合效果好，但无法输出逐网格空间分布，不能支撑空间级异常检测；其 1-shot 预测特性意味着预测值缺乏时间连续性，在需要滚动预测的场景下受限。Prophet 的 Corr = 0.9283，略低于 GRU。

LSTM 模型的 MAE = 162.35，与 GRU 接近，但训练时间显著更长（1.3 分钟）。这表明在简单时序建模任务上，门控机制的简化并未带来性能损失。

GCN 和 GAT 模型在城市级聚合预测上表现较差（MAE > 300），主要原因是这类模型设计用于逐节点预测，在城市级聚合指标上天然处于劣势。

7.2 时空联合建模实验

Week4 阶段的时空联合建模实验评估了 STGCN、AGFormer 和 STF 三种架构在 32×32 网格逐格点预测任务上的性能。

STF 模型以 222K 参数量取得综合最优性能，MAE = 327.19，RMSE = 540.17，Corr = 0.8043。STF 在训练 1 个 epoch 后即达到最优性能，表明其时空分解设计具有高效的参数利用率。

AGFormer 模型的 MAE = 386.91，RMSE = 655.39，Corr = 0.6990。AGFormer 的参数量为 2.26M，是 STF 的 10 倍，但性能反而更差。这表明在当前数据规模下（2784 训练步），大规模模型存在严重的过拟合问题。

STGCN 模型的 MAE = 429.18，RMSE = 727.29，Corr = 0.6502。STGCN 的 Chebyshev 多项式近似在空间建模上存在精度损失，且时间卷积的感受野受限固定 kernel size。

消融实验量化了 STF 各组件的贡献。移除环境 token 和跨节点注意力后，MAE 上升至 334.39（+2.2%），验证了这两个组件的有效性。移除自适应邻接矩阵对 AGFormer 性能影响更为显著，MAE 上升 5.1%，表明自适应邻接矩阵是该模型的关键组件。

7.3 异常检测实验

Week5 阶段的异常检测实验系统评估了融合框架在验证集和测试集上的性能。

单路检测器性能（验证集，F1 @ 最优阈值）：

统计阈值法（F1 = 0.7929）在单独使用时已达到较高的检测精度，其优势在于完全基于规则，不依赖模型预测。预测误差法的 V2 版本（F1 = 0.7687）因 STF 权重加载问题而受限，退化为历史均值基线。修复后的 V3 版本使用真实 STF 推理后，单路 F1 仍低于统计法，但提供了正交的检测信息。VAE 与 Transformer 自编码器在本数据集稀疏局部异常场景下，单路检测精度低于统计法与预测法，易引入热点区域噪声。

早期探索版（V3 草稿）未严格隔离验证集与测试集，直接在测试集上调参得到权重 (0.5, 0.5)、阈值 0.540，
最终交付版（V3 正式版）严格遵循验证集调参、测试集单次评估原则，仅在验证集上完成权重与阈值的网格搜索。实验表明：统计阈值法与预测误差法的最优权重为 0.9:0.1，统计法作为主信号控制误报，预测法作为补充降低漏检；VAE 与 Transformer 自编码器对本场景增益极低，未纳入最优组合。

这一结果揭示了融合检测的核心价值：统计法和预测法捕获了不同维度的异常信息。统计法擅长捕获与历史模式显著偏离的异常，预测法擅长捕获与模型预期不符的异常。两者互补，实现了检测精度与召回率的平衡。

7.4 Optuna 超参优化

Week7 阶段的 Optuna 超参优化进一步提升了 STF 模型的预测精度。

搜索空间涵盖学习率、批次大小、隐藏层维度、注意力头数、编码器层数和 Dropout 率等 7 个超参数。共运行 30 个 trial，其中 17 个通过 MedianPruner 早停被剪枝，13 个完整运行。

最优参数配置为：学习率 = 1.176e-4（相比默认 1e-3 降低 8.5 倍），批次大小 = 8，隐藏维度 = 64，注意力头数 = 2（相比默认 4 减半），编码器层数 = 1（相比默认 2 减半），Dropout = 0.137。

优化结果：测试集 MAE 从 597.70 降至 297.55（降低 50.2%），测试集 RMSE 从 831.76 降至 480.34（降低 42.2%），方向准确率从 0.5039 提升至 0.6128（提升 10.9 个百分点）。

关键发现：最优参数普遍倾向于更简单的模型配置（更少层数、更少头数、更低学习率），这与 "小数据集应避免过拟合" 的直觉一致。Optuna 通过数据驱动方式验证了这一经验法则。

7.5 系统性能评估

端到端 API 性能测试结果：

冷启动场景下，/api/anomaly/detect 端点平均响应时间为 1276ms，主要耗时在模型推理和数据加载。

缓存命中场景下，同一时间窗口的重复请求响应时间降至 9.8ms，加速比达到 130 倍。这验证了 LRU 缓存策略的有效性。

批量处理模式下（600 个时间步全量扫描），系统吞吐量为 337 步 / 秒，内存占用峰值 1.4GB。

实时推理模式下（单步滚动更新），平均延迟 15.8ms，p95 延迟 18.1ms，p99 延迟 18.3ms，满足实时预警的延迟要求。注：实时推理模式为压测得到的理论性能上限；系统线上演示采用预计算 + LRU 缓存模式，兼顾响应速度与稳定性。

第八章 可解释性分析

8.1 SHAP 特征重要性分析

SHAP（SHapley Additive exPlanations）值提供了模型预测的特征归因解释。本项目使用基于采样的 KernelExplainer 对 STF 模型的验证集预测进行 SHAP 特征归因分析。

全局特征重要性方面，历史同期均值流量（target_grid_in）是最重要的预测特征，SHAP 绝对值均值为 0.0196。这表明模型主要依赖历史同期信息进行预测，符合城市人流的强周期性规律。

时间特征中，小时（hour）和星期（day_of_week）的重要性较高，分别排名第 3 和第 5。这验证了城市人流的双周期特性（日内周期和周周期）。

空间特征中，核心区网格（row $\in$ [8, 24], col $\in$ [8, 24]）的 POI 密度对预测有显著贡献，表明城市功能区划对人流分布有重要影响。

气象特征中，温度对预测的贡献最为显著，这可能与北京冬季取暖需求和夏季空调使用有关。

8.2 注意力头分析

STF 模型的多头注意力机制提供了模型内部计算过程的解释窗口。本项目通过注意力 hook 提取了各注意力头在验证集上的平均注意力分布。

空间注意力分析显示，不同注意力头捕获了不同尺度的空间依赖。H0（第一个注意力头）倾向于捕获局部邻居的空间信息，注意力方差较低。H1（第二个注意力头）倾向于捕获长程空间依赖，注意力方差比 H0 高 2.4 倍。这表明模型通过多头分工实现了多尺度空间建模。

时间注意力分析显示，早高峰时段（7:00-9:00）的注意力分布与其他时段存在显著差异。在早高峰时段，模型对前一天的同一时段给予更高的注意力权重，表明模型学习到了 "今天是周一早高峰" 的通勤规律。

8.3 异常归因分析

本项目对检测到的异常事件进行了归因分析，探究异常发生的潜在原因。

节假日效应方面，春节期间的出租车流量显著低于正常工作日，异常事件集中在春节假期前后 3 天。清明节期间的流量模式以祭祀区域人流激增为特征，与春节的全国性流动模式不同。

气象因素方面，暴雨天气会导致出租车流量骤降，同时增加路网拥堵区域的出租车等待时间。高温天气（> 35°C）会导致出租车空调使用率上升，部分乘客转向公共交通。

事件关联方面，部分检测到的异常事件与新闻报道的交通事故、道路施工等信息存在时间和空间上的关联。这验证了异常检测结果的合理性。

第九章 总结与展望

9.1 主要工作总结

本项目构建了一套完整的多源时空数据融合城市人流异常检测系统，主要贡献包括：

在数据层面，建立了涵盖出租车 GPS、气象、POI 和路网的多源数据采集和清洗流水线，实现了从原始数据到模型输入的端到端自动化处理。数据质量通过 PO bit-for-bit 校验和缺失值溯源分析得到保障。

在模型层面，系统评估了 10 种时序和时空预测模型，量化了各模型的适用场景和性能边界。STF 模型以 222K 的轻量化参数取得了最优综合性能，其时空分解设计理念为城市级时空建模提供了新思路。

在检测层面，构建了多范式融合异常检测框架，通过数据驱动的权重搜索实现了多检测器的最优组合。最终版本严格遵循验证集调参原则，。

在系统层面，实现了 FastAPI 和 Streamlit 的服务化部署，将研究成果转化为可实际使用的工具。API 响应时间在缓存命中时低于 10ms，满足实时预警的工程需求。

在可解释性层面，通过 SHAP 和注意力图揭示了模型的决策机制，增强了系统的可信度和可解释性。

9.2 技术难点与创新点

本项目在实施过程中克服了多项技术难点：

异常注入失真问题是首个重大挑战。初期注入比例仅 0.03%，远低于验证集目标 4%，导致所有模型性能失效。通过重新设计注入逻辑，按目标比例反向计算注入事件数，并增加注入结果的强制校验，恢复了实验的有效性。

预测误差法链路断裂是第二个技术难点。STF 权重加载失败导致预测法退化为恒零预测。通过排查路径冲突、checkpoint 结构兼容和 horizon 偏移问题，重写了完整的 STF 推理链路，使预测法真正发挥作用。

融合权重搜索空间爆炸是第三个难点。四种检测器 × 多档阈值 × 连续权重组合构成指数级搜索空间。通过分阶段搜索（先固定阈值搜权重，再固定权重搜阈值）将搜索复杂度从 $O(n^4)$ 降至 $O(n^2)$ 。

本项目的主要创新点包括：

STF 时空分解架构将联合时空建模分解为时间和空间的分别处理，通过环境 token 编码全局上下文，在保持模型表达能力的同时显著降低了参数量和过拟合风险。

多范式融合检测框架整合了基于规则、基于预测、基于重构等多种检测思路，通过验证集网格搜索确定最优融合权重，实现了不同检测器的优势互补。

Optuna 超参优化揭示了 "小数据集应避免过拟合" 的设计原则，通过系统性地搜索超参空间，将 STF 测试集 MAE 降低了 50%。

9.3 局限性分析

尽管本项目取得了较好的实验结果，但仍存在以下局限性：

数据规模受限是首要局限。P4 时段共 3888 小时数据，其中训练集仅 2784 小时。在如此有限的数据规模下，大规模模型（如 AGFormer）难以发挥其表达能力。未来可考虑引入更多数据源或使用预训练策略。

网格划分固定是第二个局限。32 × 32 的网格划分是一种粗糙的空间离散化，可能无法捕捉细粒度的空间异质性。未来可考虑多尺度网格划分或使用连续的坐标回归。

异常类型有限是第三个局限。当前仅考虑突增、突降和持续三种异常类型，未覆盖周期性异常（如周期性拥堵）、渐变异常（如长期工程施工影响）等更复杂的模式。

9.4 未来工作展望

基于本项目的研究成果和局限性分析，未来工作可从以下方向展开：

第一，引入多源预训练策略。利用更大规模的城市交通数据集（如上海、深圳、成都）进行预训练，再在 TaxiBJ 数据上进行微调，有望缓解数据规模受限的问题。

第二，探索自适应网格划分。结合 POI 密度和道路网络结构，使用聚类算法自动发现功能区边界，实现数据自适应的空间离散化。

第三，扩展异常类型覆盖。引入周期性异常和渐变异常的检测模式，构建更全面的异常检测体系，

第四，增强实时预警能力。结合流式数据处理框架，实现真正的在线学习和实时异常检测，而不仅是基于历史数据的离线分析。

第五，构建端到端联合优化框架。将异常检测目标直接融入模型训练过程，而非仅作为后处理步骤，可能进一步提升检测性能。

参考文献

由于本报告基于项目内部文档整理，核心参考文献已在各周报告和代码注释中标注。主要引用的技术方案包括：SpacetimeFormer（时空分解 Transformer 架构）、STGCN（时空图卷积网络）、AGFormer（自适应图时空 Transformer）、Prophet（Facebook 时序预测框架）、Optuna（超参优化框架）和 SHAP（深度学习可解释性方法）。

本报告完成于 2026 年 8 月 17 日，报告内容基于项目实验数据和运行结果生成，所有数字均经过实测验证，